Aprendizagem contrastiva para classificação fiscal

Como SBERT e MNR aprendem a representar descrições de produtos

Anggoro, Corcoran, De Widt e Li (2025)
Data Technologies and Applications, 59(2), 279–301.

Welyab Paula | PECS / UEMA

Fonte: Anggoro et al. (2025), resumo e folha de identificação ORCA.

Descrições diferentes podem ter o mesmo código

O sistema recebe texto livre e precisa prever uma classe fiscal.

Descrição ilustrativa	Classe
Notebook Lenovo ThinkPad, SSD 512 GB	A
Laptop ThinkPad Lenovo, armazenamento 512GB	A
Monitor LCD para computador	B

O modelo precisa reconhecer semelhanças relevantes para a classe.

A/B são classes didáticas, sem enquadramento fiscal real.

Fonte: Anggoro et al., introdução e seção 3.1. Exemplo didático elaborado para a apresentação.

Um embedding representa o texto em números

Descrição do produto

$$\downarrow \quad f_\theta$$

$$\mathbf{z} = (z_1, z_2, \ldots, z_{768})$$

- O **encoder** f_θ transforma textos em vetores de tamanho fixo.
- Cada dimensão é aprendida; não corresponde a uma coluna como peso ou marca.
- Textos com comprimentos diferentes podem ser comparados no mesmo espaço.

A qualidade do vetor determina o que o classificador consegue distinguir.

Fonte: Anggoro et al., seções 3.2 e 4.3.1; explicação didática da representação.

Pooling reúne os tokens em um único vetor

BERT ou DistilBERT produz um vetor contextual para cada token.

$$h_1,\ h_2,\ \ldots,\ h_m \quad \xrightarrow{\text{pooling}} \quad \mathbf{z} \in \mathbb{R}^{768}$$

Estratégia	Como obtém a representação do texto
Média	Calcula a média dos vetores dos tokens.
Máximo	Seleciona o maior valor em cada dimensão.
[CLS]	Usa o vetor do token especial de classificação.

O estudo monta o SBERT com encoders já pré-treinados e ajusta seus parâmetros.

Fonte: Anggoro et al., seções 3.2 e 4.3.1.

Os dois ramos do SBERT compartilham pesos

Rede siamesa / bi-encoder: cada texto é codificado separadamente.

$$\text{Descrição âncora } a \xrightarrow{f_\theta} \text{Vetor } \mathbf{z}_a$$

$$\text{Descrição positiva } b \xrightarrow{f_\theta} \text{Vetor } \mathbf{z}_b$$

- Os dois ramos usam **o mesmo encoder e o mesmo pooling**.
- A perda compara os vetores e atualiza os parâmetros compartilhados.
- Depois do ajuste, cada descrição pode gerar seu embedding individualmente.

Fonte: Anggoro et al., seção 3.2 e Figura 1.

O código conhecido orienta a aproximação

Âncora + outra transação do mesmo código = par positivo.

Papel	Descrição ilustrativa	Classe
Âncora	Notebook Lenovo ThinkPad, SSD 512 GB	A
Positivo	Laptop ThinkPad Lenovo, 512GB	A
Outro produto	Monitor LCD para computador	B

- **Supervisionada:** os rótulos definem quais pares são positivos.
- **Contrastiva:** o par positivo é comparado com alternativas.
- Os pares usam transações reais, preservando o texto original.

Fonte: Anggoro et al., seção 3.2 e Figura 2. Exemplo didático; classes A/B hipotéticas.

O cosseno compara a direção dos vetores

$$\text{sim}(\mathbf{u}, \mathbf{v}) = \frac{\mathbf{u}^\top \mathbf{v}}{\|\mathbf{u}\| \, \|\mathbf{v}\|}$$

Similaridade de cosseno

Compara a direção, normalizando o comprimento dos vetores.

Direções próximas: cosseno próximo de 1.

Produto escalar

Usa $\mathbf{u}^\top \mathbf{v}$ sem normalização.

Depende da direção e também da magnitude.

Similaridade é um escore entre textos; não é a probabilidade de um código.

Fonte: Anggoro et al., seção 3.3; formulação didática da similaridade de cosseno.

Cada positivo também é candidato no lote

Lote com três pares: (a_1, b_1), (a_2, b_2) e (a_3, b_3).

Similaridade	b_1	b_2	b_3
a_1	**0,80**	0,30	0,10
a_2	0,20	**0,75**	0,15
a_3	0,10	0,25	**0,85**

- **Diagonal:** positivo correspondente a cada âncora.
- **Fora da diagonal:** negativos obtidos dos outros pares.
- A MNR favorece a diagonal diante das alternativas.

Exemplo ilustrativo: três pares de classes distintas.
Fonte: Anggoro et al., seção 3.3 e Apêndice II. Matriz numérica didática.

A MNR penaliza a baixa preferência pelo positivo

Primeira linha: positivo b_1 com escores $(0{,}80;\ 0{,}30;\ 0{,}10)$.

1. **Escala:** com $s = 2$, os escores viram $(1{,}60;\ 0{,}60;\ 0{,}20)$.
2. **Softmax:** transforma esses escores em preferências relativas.

$$p(b_1 \mid a_1) = \frac{e^{1{,}60}}{e^{1{,}60} + e^{0{,}60} + e^{0{,}20}} \approx 0{,}619$$

3. **Perda:** $-\log(0{,}619) \approx 0{,}479$; o ajuste busca reduzi-la.

Maior preferência pelo positivo $\Rightarrow$ menor perda.

Escala 2 apenas para ilustrar o cálculo; o artigo avalia 20 e 50.

Fonte: Anggoro et al., seção 3.3 e Apêndice II; cálculo didático da MNR padrão.

Aprender o vetor e prever o código são duas etapas

1. Ajustar o SBERT

70% das transações

Descrições + códigos

↓

Pares positivos + MNR

↓

Encoder ajustado ao domínio

2. Treinar o classificador

30% das transações

Embeddings do SBERT ajustado

↓

SVM ou Random Forest

↓

Validação estratificada: 5 folds

Nova descrição:

Texto → SBERT ajustado → vetor → classificador → código

Fonte: Anggoro et al., seção 3.1, seção sobre classificadores e seção 5.1.

O teste abrange duas bases desbalanceadas

	Índia, 2016	EUA, 2018
Transações	66.522	58.003
Classes	172	112

Recorte: descrições em inglês, capítulos 84 e 85 do HS.

Desbalanceamento: razão média relatada de 30:1.

F1 ponderado

Combina precisão e revocação; pesa as classes pela frequência.

Macro-F1

Dá o mesmo peso a cada classe; complementa a leitura das classes raras.

Fonte: Anggoro et al., seções 3.1 e 5.1; Tabelas I e III.

Embeddings ajustados melhoram a classificação

F1 ponderado na comparação principal

Método	Índia	EUA
BERT ajustado diretamente	0,8406	0,7689
SBERT/BERT + SVM	0,8620	**0,8013**
SBERT/BERT + Random Forest	**0,8656**	0,8005

+2,50 p.p.
Índia: SBERT/BERT + RF.

+3,24 p.p.
EUA: SBERT/BERT + SVM.

Ganhos sobre o BERT ajustado diretamente, nas mesmas bases.

Fonte: Anggoro et al., Tabela III. Ganhos em pontos percentuais calculados.

A limpeza pode apagar o sinal que importa

Especificações como `512GB` também ajudam a representar o produto.

SBERT/DistilBERT + SVM: F1 ponderado

Base	Original	Após limpeza	Queda
Índia	0,8603	0,7790	8,13 p.p.
EUA	0,7953	0,7185	7,68 p.p.

- **LIME:** uma explicação local indica influência de atributos técnicos.
- A evidência vale para a limpeza testada; não condena toda normalização.

Fonte: Anggoro et al., seção 3.1, Tabela IV e Figura 3.

Mais positivos expõem variações da mesma classe

Uma âncora $\longrightarrow$ três descrições do mesmo código

SBERT/DistilBERT: ganho no F1 ponderado

Classificador	Ganho: Índia	Ganho: EUA
SVM	+2,43 p.p.	+2,18 p.p.
Random Forest	+2,27 p.p.	+2,70 p.p.

- Mais pares oferecem diversidade ao ajuste do encoder.
- O custo de treinamento cresce; não foi estabelecido um número ótimo.

Fonte: Anggoro et al., seções 3.2 e 4.3.1; Tabela V. Ganhos calculados.

A qualidade dos pares limita o aprendizado

- **Rótulos declarados:** um código incorreto pode formar um par inadequado.
- **Negativos do lote:** outro par do mesmo código pode gerar um falso negativo.
- **Generalização:** dois países e dois capítulos não cobrem toda a nomenclatura.
- **Custo:** ajustar o encoder e armazenar o classificador exige recursos.

Proximidade no espaço vetorial não assegura conformidade com regras fiscais.

Rótulos e falsos negativos: leitura crítica do método; efeitos não medidos no artigo.

Fonte: Anggoro et al., seções 3 e 5, Tabela III e conclusão; leitura crítica do protocolo.

O rótulo ensina o modelo a comparar descrições

1. **SBERT** transforma cada descrição em um embedding.
2. **Os códigos conhecidos** definem os pares positivos.
3. **A MNR** favorece esses pares diante dos candidatos do lote.
4. **SVM ou Random Forest** convertem os embeddings em previsões.

Aprender uma representação adequada ao domínio melhora a classificação nas bases estudadas.

Fonte: Anggoro et al., Figura 1, Tabela III e conclusão.

A MNR é uma entropia cruzada sobre o lote

Para um lote de n pares positivos (a_i, b_i):

$$\mathcal{L}_{\rightarrow} = -\frac{1}{n}\sum_{i=1}^{n} \log \frac{\exp(s\ \mathrm{sim}(f_\theta(a_i), f_\theta(b_i)))}{\sum_{j=1}^{n} \exp(s\ \mathrm{sim}(f_\theta(a_i), f_\theta(b_j)))}.$$

- s: escala das similaridades; o alvo de cada linha é o índice i.
- O denominador inclui o positivo e os demais candidatos.
- A escala altera a concentração da softmax; não muda a ordem dos escores.

MNR simétrica: $\mathcal{L}_{\mathrm{sim}} = \frac{1}{2}(\mathcal{L}_{\rightarrow} + \mathcal{L}_{\leftarrow})$.

No sentido inverso, cada positivo busca sua âncora correspondente.

Fonte: Anggoro et al., seção 3.3, seção 4.3.2 e Apêndice II; formulação didática da MNR padrão.

As escolhas de ajuste têm efeitos diferentes

Comparação	Resultado observado
Média / máximo / [CLS]	Resultados próximos; sem vencedor universal.
MNR / MNR simétrica	Ganhos pequenos com a versão simétrica.
Escala 20 / 50	A escala 50 não melhora os resultados.
Lote 8 / 32	Ganhos de 0,14 a 0,36 p.p. com lote maior.
10 / 30 épocas	Ganhos de 1,19 a 2,01 p.p. com mais épocas.
Taxa $2 \cdot 10^{-5}$ / $5 \cdot 10^{-5}$	A menor taxa tem melhores resultados.

Variações do F1 ponderado nas configurações das Tabelas VI–VIII.

Fonte: Anggoro et al., Tabelas III e VI–VIII. Intervalos calculados a partir dos valores publicados.

Fonte principal e fundamentos técnicos

Anggoro, A. W.; Corcoran, P.; De Widt, D.; Li, Y. (2025).

Harmonized System Code Classification using Supervised Contrastive Learning with Sentence BERT and Multiple Negative Ranking Loss.

Data Technologies and Applications, 59(2), 279–301.
DOI: 10.1108/DTA-01-2024-0052. Versão dos autores, ORCA.

Fundamentos citados no artigo

- Reimers e Gurevych (2019): Sentence-BERT.
- Henderson et al. (2017): aprendizagem com múltiplos negativos.
- Ribeiro et al. (2016): explicações locais com LIME.

Exemplos A/B, matriz de similaridade e cálculo numérico: ilustrações didáticas.

Fonte: Anggoro et al. (2025), folha ORCA, corpo do manuscrito e bibliografia.