

Ajuste contrastivo para classificação de produtos

Harmonized System Code Classification using Supervised Contrastive Learning with Sentence BERT and Multiple Negative Ranking Loss

Angga Wahyu Anggoro, Padraig Corcoran,
Dennis De Widt e Yuhua Li
Data Technologies and Applications, 59(2), 279–301, 2025

Problema: prever o código HS a partir de descrições comerciais curtas, técnicas e pouco padronizadas.

Apresentação: Welyab Paula | PECS / UEMA

Fonte: Anggoro et al. (2025), resumo. DOI: 10.1108/DTA-01-2024-0052.

A conexão está nos embeddings

Nosso artigo sobre NF-e

- Descrições em português.
- Embeddings prontos: MiniLM, MPNet e E5.
- Classificação de capítulos NCM em recortes de 2 e 4 classes.

Anggoro et al. (2025)

- Descrições comerciais em inglês.
- SBERT ajustado com pares do mesmo código.
- 172 e 112 classes em produtos dos capítulos 84 e 85.

A diferença metodológica

Ajustar a representação dos textos **antes** de treinar o classificador.

Fonte: Paula et al., seções 3–4; Anggoro et al. (2025), seção 4.1 e Tabela I.

Aprender quais descrições aproximar

Ajuste contrastivo: aprender embeddings que reconheçam pares relacionados.

Papel	Descrição ilustrativa	Rótulo
Âncora	Camiseta masculina 100% algodão	Código A
Positivo	Camiseta masc. de algodão	Código A
Negativo	Carregador para telefone celular	Código B

Aproximar âncora e positivo; reduzir a similaridade com os negativos.

- O mesmo código define os pares positivos.
- A perda MNR usa os outros exemplos do lote como negativos.

Exemplo didático; códigos A/B não representam enquadramentos fiscais reais.

Fonte: Anggoro et al. (2025), seções 3.3 e 4, construção dos pares e Multiple Negative Ranking Loss.

O método combina ajuste e classificação

Base de importações	Transações	Classes
Índia (2016)	66.522	172
Estados Unidos (2018)	58.003	112

Textos em inglês; capítulos 84 e 85; classes desbalanceadas.

Descrições + códigos → **Pares positivos**



SBERT + perda MNR → **Embeddings**



SVM / Random Forest → **Código previsto**

70%: ajuste do SBERT. 30%: treino e avaliação dos classificadores.

Validação cruzada estratificada com 5 partições.

Fonte: Anggoro et al. (2025), seções 4.1 e 5.1; Tabela I.

O ajuste melhora o F1; a limpeza prejudica

F1 ponderado: comparação com BERT ajustado diretamente

Método	Índia	EUA
BERT ajustado diretamente	0,8406	0,7689
SBERT/BERT + SVM	0,8620	0,8013
SBERT/BERT + Random Forest	0,8656	0,8005

Melhor ganho: **+2,50 pontos percentuais** na Índia e **+3,24** nos EUA.

Limpeza: SBERT/DistilBERT + SVM

Índia: texto original **0,8603** → texto limpo **0,7790**.

Queda de **8,13 pontos percentuais** no F1 ponderado.

Remover informações alfanuméricas pode eliminar atributos técnicos úteis.

Fonte: Anggoro et al. (2025), Tabelas III e IV; diferenças calculadas a partir dos valores publicados.

Uma hipótese concreta para as NF-e

Contribuição

Aprender representações específicas de transações melhora os classificadores avaliados.

Limitações

- Dois capítulos e textos em inglês.
- Sem demonstrar transferência entre países ou desempenho na NCM brasileira.
- F1 ponderado deve ser lido junto às métricas das classes raras.

Possível aplicação

Comparar MiniLM original e ajustado em NF-e, com códigos mais detalhados e uma amostra validada por especialistas.

O ajuste mantém o ganho em emitentes e períodos não vistos?

Fonte: Anggoro et al. (2025), seções 4–6; Paula et al., seções 3 e 5. Aplicação e pergunta: avaliação do apresentador.