

Ajuste contrastivo para classificação fiscal

Harmonized System Code Classification using Supervised Contrastive Learning with Sentence BERT and Multiple Negative Ranking Loss

Angga Wahyu Anggoro, Padraig Corcoran,
Dennis De Widt e Yuhua Li

Data Technologies and Applications, 59(2), 279–301, 2025

Welyab Paula | PECS / UEMA

Fonte: Anggoro et al. (2025), folha ORCA e resumo.

O problema também aparece nas NF-e

Descrições livres tornam a classificação fiscal difícil.

Welyab et al.

- NF-e da SEFAZ-MA, em português.
- Embeddings prontos e classificadores supervisionados.
- Previsão de capítulos da NCM.

Anggoro et al.

- Declarações de importação, em inglês.
- Ajuste contrastivo do gerador de embeddings.
- Previsão de códigos dentro de dois capítulos.

Pergunta central

Aprender a representação no domínio melhora a classificação?

Fonte: Welyab et al., seções 3–4; Anggoro et al., resumo e seção 3.

Duas bases reais de importação

	Índia	Estados Unidos
Ano das transações	2016	2018
Fonte	Zauba	Enigma
Transações no recorte	66.522	58.003
Classes	172	112

- Descrições em inglês; dados de declarações aduaneiras.
- Recorte: capítulos **84 e 85** do Sistema Harmonizado.
- Classes desbalanceadas: razão média relatada de **30:1**.

Fonte: Anggoro et al., seção 3.1 e Tabela I.

Descrição é entrada; código é o rótulo

Entrada: descrição comercial do produto.

Pode conter marca, modelo, capacidade, dimensões e número de série.

Código	Descrição original (trecho)
84713010	X2 LAPTOP LENOVO MODEL THINKPAD T430
85285100	LED MONITOR, S22E360H, 21.5, INDIA ...
85423100	INTEGRATED CIRCUIT LOGIC MONO ASTBL ...


Features dos classificadores: 768 dimensões do embedding.

84 e 85 delimitam o recorte; não são as duas classes previstas.

Fonte: Anggoro et al., seções 3.1 e 4.3.1; Tabela II.

SBERT transforma uma descrição em vetor

Embedding: representação numérica de um texto.



- **SBERT:** arquitetura para representar textos inteiros.
- **Pooling:** agrega os vetores dos tokens (média, máximo ou [CLS]).
- O ajuste atualiza os parâmetros do codificador.

Fonte: Anggoro et al., seções 3.2 e 4.3.1.

O mesmo código define pares positivos

Aprendizagem contrastiva supervisionada

Usar o rótulo fiscal para decidir quais descrições aproximar.

Papel	Descrição ilustrativa	Classe
Âncora	Notebook Lenovo ThinkPad 512 GB	A
Positivo	Laptop ThinkPad Lenovo, SSD 512GB	A
Negativo	Monitor LCD para computador	B

Aproximar a âncora do positivo e favorecer sua distinção dos negativos.

Exemplo didático: A/B não são enquadramentos fiscais reais.

Fonte: Anggoro et al., seção 3.2 e Figura 2. Exemplo elaborado para esta apresentação.

MNR compara o positivo com os demais

MNR: Multiple Negative Ranking Loss

Função de perda já existente, aplicada ao ajuste do SBERT.

	Positivo b_1	Positivo b_2
Âncora a_1	par correto	negativo do lote
Âncora a_2	negativo do lote	par correto

- A perda favorece maior similaridade para o par correto.
- Usa outros positivos do lote como negativos de cada âncora.
- Similaridade por cosseno ou produto escalar.

Cuidado: outro item do mesmo código pode virar um falso negativo.

Fonte: Anggoro et al., seção 3.3 e Apêndice II. Falsos negativos: análise do apresentador.

Há dois treinamentos separados

1. Ajustar a representação

70% das transações

Descrições + códigos



Pares positivos



SBERT treinado com MNR

2. Treinar o classificador

30% das transações

SBERT ajustado gera vetores



SVM ou Random Forest



Validação estratificada: 5 folds

Uso em uma descrição nova

Texto → SBERT ajustado → vetor → classificador → código

Fonte: Anggoro et al., seção 3.1, seção sobre classificadores e seção 5.1.

Os experimentos isolam escolhas do método

Escolha	Alternativas avaliadas
Codificador	BERT / DistilBERT (base, uncased)
Texto	Original / pré-processado
Pares positivos	1 / 3 por âncora
Pooling	Média / máximo / [CLS]
Perda	MNR / MNR simétrica; cosseno / produto escalar
Treinamento	Lotes 8/32; épocas 10/30; taxas 0,00002 / 0,00005

Classificadores: SVM e Random Forest, em configurações padrão.

Execução com GPU; comparação com BERT/DistilBERT ajustados diretamente.

Fonte: Anggoro et al., seções 4.2–4.3 e Tabelas III–VIII.

O F1 deve ser lido junto ao desbalanceamento

- **Precisão:** entre as previsões de uma classe, quantas estão corretas?
- **Revocação:** entre os itens da classe, quantos foram recuperados?
- **F1:** combina precisão e revocação.

F1 ponderado

Pesa cada classe pela sua frequência. É o foco das comparações do artigo.

Um bom resultado agregado não garante bom desempenho em cada código.

Macro-F1

Dá o mesmo peso a cada classe. Ajuda a avaliar classes menos frequentes.

Fonte: Anggoro et al., seção 5.1 e Tabela III.

O ajuste contrastivo supera a referência

F1 ponderado

Método	Índia	EUA
BERT ajustado diretamente	0,8406	0,7689
SBERT/BERT + SVM	0,8620	0,8013
SBERT/BERT + Random Forest	0,8656	0,8005

+2,50 p.p.

Melhor ganho na Índia.

+3,24 p.p.

Melhor ganho nos EUA.

Ganhos calculados em relação ao BERT da Tabela III.

Fonte: Anggoro et al., Tabela III; diferenças calculadas a partir dos valores publicados.

A limpeza remove informação útil

SBERT/DistilBERT + SVM: F1 ponderado

Base	Original	Limpo	Variação
Índia	0,8603	0,7790	−8,13 p.p.
EUA	0,7953	0,7185	−7,68 p.p.

O que pode se perder?

Modelo, capacidade e especificações como **512 GB**.

- LIME: explica localmente quais termos influenciam uma previsão.
- O exemplo do artigo indica relevância de atributos técnicos.

Fonte: Anggoro et al., seção 3.1, seção 5.3, Tabela IV e Figura 3.

Mais positivos enriquecem o ajuste

SBERT/DistilBERT: F1 ponderado

Base	Modelo	1 positivo	3 positivos	Ganho
Índia	SVM	0,8360	0,8603	+2,43 p.p.
Índia	RF	0,8410	0,8637	+2,27 p.p.
EUA	SVM	0,7735	0,7953	+2,18 p.p.
EUA	RF	0,7688	0,7958	+2,70 p.p.

Interpretação: mais descrições da mesma classe oferecem maior diversidade ao treinamento.

O benefício tem custo: mais pares e maior tempo de ajuste.

Fonte: Anggoro et al., seção 3.2, seção 4.3.1 e Tabela V; ganhos calculados.

O ganho também tem custo de armazenamento

- **Pooling:** resultados próximos; nenhuma opção domina todas as configurações.
- **MNR simétrica e escala:** mudanças pequenas nos cenários avaliados.
- **Treinamento:** 30 épocas e taxa 0,00002 favorecem os resultados; lotes maiores trazem ganhos modestos.

Tamanho relatado na base indiana

	F1 ponderado	Tamanho
BERT ajustado diretamente	0,8406	418 MB
SBERT/DistilBERT + SVM	0,8603	291 MB
SBERT/BERT + RF	0,8656	631 MB

Fonte: Anggoro et al., Tabelas III e VI–VIII.

Como a MNR calcula a perda

Em cada lote de pares positivos:

1. Calcular a similaridade de cada âncora com todos os candidatos do lote.
2. Aplicar a escala e converter os escores em probabilidades (softmax).
3. Penalizar o modelo quando o positivo correto recebe baixa probabilidade.
4. Atualizar o codificador para reduzir essa perda.

MNR simétrica: também avalia os pares no sentido inverso.

A perda padrão é a entropia cruzada sobre os candidatos do lote.

Fonte: Anggoro et al., seção 3.3, Tabela VII e Apêndice II; descrição didática do cálculo.

Fontes utilizadas

Anggoro, A. W.; Corcoran, P.; De Widt, D.; Li, Y. (2025).

Harmonized System Code Classification using Supervised Contrastive Learning with Sentence BERT and Multiple Negative Ranking Loss.

Data Technologies and Applications, 59(2), 279–301.

DOI: 10.1108/DTA-01-2024-0052. Versão dos autores, ORCA.

Paula, W.; Jacob Junior, A. F. L.; Cortes, O. A. C.; Lobato, F. M.

Avaliação de Large Language Models Para Classificação de Produtos da Nota Fiscal Eletrônica em Grupos da Nomenclatura Comum do Mercosul.

Manuscrito local: artigo_welyab_pecs.pdf.

Referências técnicas citadas por Anggoro

Reimers e Gurevych (2019): SBERT. Henderson et al. (2017): aprendizagem com negativos.

Ribeiro et al. (2016): LIME.

Fonte: PDFs locais de Anggoro et al. e Welyab et al.; bibliografia de Anggoro.