

Avaliação de Large Language Models Para Classificação de Produtos da Nota Fiscal Eletrônica em Grupos da Nomenclatura Comum do Mercosul

Welyab Paula^{1,3}, Antonio Fernando Lavareda Jacob Junior¹,
Omar Andres Carmona Cortes^{1,2}, Fábio Manoel Franca Lobato^{1,4}

¹ Programa de Pós-Graduação em Engenharia da Computação e Sistemas (PECS)
Universidade Estadual do Maranhão (UEMA)
Cidade Universitária Paulo VI – Jardim São Cristóvão – 65.055-310 – São Luís/MA – Brasil

² Departamento de Computação (DComp) – Instituto Federal do Maranhão (IFMA)
Av. Getúlio Vargas, 04 – Monte Castelo – 65030-005 – São Luís/MA – Brasil

³ Engenharia de Computação – Universidade Federal do Maranhão (UFMA)
Av. dos Portugueses, 1966 – Bacanga – Cidade Universitária Dom Delgado
65.080-805 – São Luís/MA – Brasil

⁴ Instituto de Engenharia e Geociências – Universidade Federal do Oeste do Pará (UFOPA)
Rua Vera Paz – Maracanã – 68035-110 – Santarém/PA – Brasil

welyab.exe@gmail.com, antoniojunior@professor.uema.br

omar@ifma.edu.br, fabio.lobato@ufopa.edu.br

Resumo. A Nota Fiscal Eletrônica (NF-e) é composta por informação fornecida pelos contribuintes. É fundamental que as informações estejam corretas. Um dos principais tributos é o ICMS, de responsabilidade dos estados. Cabe às Secretarias Estaduais da Fazenda fiscalizar a validade das informações e cobrar o imposto devido. A descrição do produto é um campo livre, sujeito a todo tipo de ambiguidade, de modo que inviabiliza a validação manual em relação ao enquadramento fiscal indicado pelo contribuinte. Com isso, este trabalho avalia o uso de processamento de linguagem natural (PLN) com large language models (LLM) e representações semânticas (embeddings) para classificar descrições de produtos contra seus grupos da Nomenclatura Comum do Mercosul (NCM). O experimento foi conduzido em Python e superou trabalhos semelhantes alcançando precisão, recall e f1-score de 98,5%.

Abstract. The Brazilian Electronic Tax Invoice (NF-e) is composed of information provided by taxpayers. It is essential that such information be accurate. One of the main taxes involved is the ICMS, which is under the responsibility of the Brazilian states. State Treasury Departments are responsible for verifying the validity of the information and collecting the corresponding tax. Product description is a free-text field, subject to various forms of ambiguity, which makes manual validation of the fiscal classification indicated by the taxpayer impractical. In this context, this work evaluates the use of Natural Language Processing (NLP) techniques with Large Language Models (LLMs) and semantic representations (embeddings) to classify product descriptions against their

corresponding groups in the Mercosur Common Nomenclature (NCM). The experiment was conducted in Python and outperformed related studies, achieving a precision, recall and an f1-score of 98.5%.

1. Introdução

A NF-e modernizou o controle tributário nacional ao introduzir um documento fiscal eletrônico comum, com validade jurídica e compartilhada com todos os entes da federação [ENCAT 2020a]. A legislação tributária impõe aos contribuintes a obrigação de preencher as notas fiscais com informações que descrevam fielmente a operação realizada [Brasil 1996]. Parte dessas informações é composta por campos estruturados estabelecidos pela NF-e, os quais seguem padrões previamente definidos em função da mercadoria transacionada.

Nesse sentido, [Mendonça et al. 2022] indicam que a Nota Fiscal Eletrônica (NF-e) constitui o principal instrumento de apoio à fiscalização de tributos como o Imposto Sobre Circulação de Mercadorias e Serviços¹ (ICMS), em vigor desde a vigência da Constituição de 1988 [Brasil 1988], os novos Imposto Sobre Bens e Serviços (IBS) e Contribuição Sobre Bens e Serviços (CBS). O IBS e o CBS fazem parte da reforma tributária brasileira, instituída pela a Emenda Constitucional [Brasil 2023] e substituirão o ICMS e outros impostos até 2031. Essas mudanças destacam o caráter dinâmico e evolutivo da NF-e, bem como dos mecanismos de fiscalização.

Além de campos estruturados, a NF-e também possui campos cujo conteúdo é de preenchimento livre e textual, como indicado por [Mendonça et al. 2022], citando o exemplo da descrição de um produto. Por ser de preenchimento livre, utilizar a descrição do produto em controles fiscais automatizados é problemático pela falta de padrão, conforme sustentado por [Mendonça et al. 2022].

Uma informação obrigatória atribuída ao produto registrado em uma NF-e é o código da Nomenclatura Comum do Mercosul (NCM) [ENCAT 2020b]. É um código padronizado que tem por objetivo categorizar produtos em grupos específicos, como plásticos, alimentos, minerais, etc. O NCM faz parte de regras de tributação, sendo uma informação essencial para a correta apuração do imposto devido.

A descrição do produto pode ser informada de maneira inadequada, seja por equívoco operacional, seja por má fé do contribuinte, de modo a não corresponder corretamente ao grupo indicado pelo código NCM. Essa inconsistência dificulta a verificação automática da classificação fiscal, podendo resultar em enquadramento tributário incorreto e, conseqüentemente, na apuração indevida do imposto devido.

Diante de tudo isso, e considerando a importância da tecnologia no apoio às ações fiscais, a proposta deste trabalho é avaliar como modelos de processamento de linguagem natural (PLN) modernos lidam com a tarefa de auxiliar o processo classificatório de produtos.

¹No Maranhão, esse imposto representou quase 72% de toda arrecadação do estado em dezembro de 2025, cerca de R\$ 1,56 bilhão [SEFAZ-MA 2025]

2. Trabalhos correlatos

O trabalho de [Mendonça et al. 2022] usa aprendizagem de máquina para automatizar a identificação de produtos da NF-e a partir do campo de descrição. Foram comparados modelos de classificação com dados de NF-e da Secretaria da Fazenda do Maranhão (SEFAZ-MA). A Rede Neural é a mais eficiente em termos de precisão e tempo de processamento.

O algoritmo Naive Bayes foi utilizada por [Batista et al. 2018] para classificar produtos em relação ao NCM. Foram processadas descrições textuais extraídas de Notas Fiscais do Consumidor Eletrônicas (FNC-e) da Secretaria da Fazenda do Rio Grande do Sul. O modelo apresentou alto desempenho, alcançando acurácia de até 98% em conjuntos de dados específicos.

Mineração de dados foi aplicada por [Madeira 2015] para identificar fraudes fiscais no sistema da Nota Carioca, com foco no campo de descrição livre dos serviços. Utilizou-se K-means e Naive Bayes para identificar empresas que declaram incorretamente o domicílio tributário.

O trabalho de [Jatobá et al. 2021] apresenta uma ferramenta automatizada para apoiar o cálculo do ICMS em operações interestaduais destinadas a Alagoas. A solução usa um modelo baseado em regras para classificar produtos e prever tributos, incorporando um mecanismo de validação por auditores fiscais.

O trabalho de [Paula Junior et al. 2004] utiliza uma rede neural para identificar níveis de sonegação do ICMS em indústrias de móveis da Zona da Mata mineira. O modelo, treinado com indicadores contábeis e fiscais, apresentou alta precisão na classificação de empresas irregulares.

3. Materiais e métodos

Diante das dificuldades, inicialmente mencionadas, em classificar um produto a partir de sua descrição, técnicas modernas de PLN surgem como uma alternativa para apoiar a fiscalização tributária. Em particular, o uso de representações vetoriais semânticas (*embeddings*) e de modelos de linguagem de grande porte (*Large Language Models* - LLMs). Estas ferramentas possibilitam a conversão da descrição textual do produto e da descrição oficial associada ao código NCM em vetores numéricos que preservam relações semânticas. A partir dessas representações, torna-se viável medir o grau de similaridade semântica entre a mercadoria descrita na NF-e e o NCM informado [Reimers and Gurevych 2019, Cer et al. 2018].

No contexto fiscal, o NCM é um sistema padronizado de classificação de mercadorias adotado pelos países do Mercosul [SISCOMEX 2025, WCO 2026]. A finalidade é agrupar produtos de maneira uniforme no comércio, servindo de base para a aplicação de tributos, estatísticas de comércio exterior e controle aduaneiro. No Brasil, o código NCM é composto por oito dígitos e é de uso obrigatório em documentos fiscais.

Este trabalho visa criar os *embeddings* de produtos e NCMS e classificar usando alguns algoritmos, como KNN, Random Forest, SVM, MLP. Os resultados são analisados por meio de métricas quantitativas, relatórios detalhados e matrizes de confusão, com o objetivo de verificar a viabilidade do uso de *embeddings* semânticos como apoio à

fiscalização tributária e à detecção de possíveis inconsistências na classificação fiscal dos produtos.

É importante destacar que o dataset utilizado neste trabalho é oriundo de registros reais de NF-e e não passou por um processo prévio de validação manual da classificação fiscal. Assim, os códigos NCM associados aos produtos são utilizados como estão, partindo do pressuposto de que refletem o enquadramento informado pelo contribuinte e aceito pelo sistema fiscal no momento da emissão. Essa suposição é deliberada e metodologicamente justificável no contexto de um estudo preliminar e exploratório, cujo objetivo central não é auditar ou corrigir a base de dados, mas investigar a viabilidade do uso de LLMs e embeddings semânticos para capturar padrões linguísticos e semânticos entre as descrições de produtos e categorias fiscais. Ao adotar essa hipótese de correção, o trabalho estabelece um cenário controlado inicial, permitindo avaliar o potencial discriminativo das representações semânticas antes de avançar para etapas futuras, nas quais inconsistências reais, ruídos e erros de classificação poderão ser explicitamente modelados e analisados no contexto da fiscalização tributária automatizada.

O trabalho foca na criação de embeddings das descrições dos produtos da NF-e e dos capítulos (primeiros dois dígitos do código) de NCM listados abaixo:

- 22 - Bebidas, líquidos alcoólicos e vinagres
- 90 - Instrumentos e aparelhos de óptica, de fotografia, de cinematografia, de medida, de controle ou de precisão; instrumentos e aparelhos médico cirúrgicos e suas partes e acessórios
- 33 - Óleos essenciais e resinoides; produtos de perfumaria ou de toucador preparados e preparações cosméticas
- 61 - Vestuário e seus acessórios, de malha
- 39 - Plástico e suas obras
- 62 - Vestuário e seus acessórios, exceto de malha

Uma parte do treinamento aconteceu em um dataset formado pelos capítulos 22 e 90 (3500 registros de cada, são os mesmos capítulos usados no trabalho de [Batista et al. 2018]). Um segundo dataset foi montado com os capítulos 33, 39, 61 e 87 (3000 registros de cada), que correspondem aos capítulos mais frequentes no dataset da SEFAZ-MA. A seleção dos registros foi feita de forma aleatória ².

Foram usados os seguintes modelos de linguagem natural:

- `sentence-transformers/paraphrase-multilingual-base-v2`
- `sentence-transformers/paraphrase-multilingual-MiniLM-L12-v2`
- `intfloat/multilingual-e5-large`

Segundo [Wang et al. 2024], o modelo `multilingual-e5-large` foi treinado de forma que os textos eram submetidos com um marcador de consulta ("`query:` ") e um marcador de resposta ("`passage:` "). Com isso, a geração dos embeddings das descrições dos produtos foi feito com a adição do marcador de consulta, e no NCM foi adicionado o marcador de resposta.

²Foi utilizada a função `random()` do PostgreSQL

4. Experimentos

4.1. Datasets

O dataset utilizado neste trabalho é originado das NF-e do mês de março de 2025, disponibilizado pela Secretaria de Estado da Fazenda do Maranhão (SEFAZ-MA). O dataset contém uma lista de produtos com os campos de descrição e o código do NCM. O dataset tem registros dos NCM com código de capítulo 22, 90, 33, 39, 61 e 87.

Foram removidos da descrição dos produtos quaisquer caracteres não alfabéticos, incluindo números e quaisquer caracteres especiais. Depois, foram removidas palavras de até dois caracteres de tamanho e espaços repetidos. Os testes foram realizados com a descrição original e a descrição sanitizada, e também com uma concatenação de ambas, com cada teste realizado separadamente. Além disso, registros repetidos (NCM + descrição original, apenas) foram removidos.

A lista de NCM com códigos e descrições foi obtida no Portal Único do Siscomex [SISCOMEX 2025]. Trata-se de um arquivo JSON contendo as descrições dos capítulos, posições, subposições, itens e subitens. Foram usadas apenas as descrições dos capítulos selecionados.

4.2. Configuração

Os experimentos foram conduzidos em um computador pessoal equipado com processador Intel Core i7-9750H CPU de 2.60 GHz, 32 GB de memória RAM e Windows 11, além de disco SSD. Não foi utilizado recurso de GPU.

O experimento usou o ecossistema Python 3.11.8 com os seguintes módulos:

- pandas 2.3.3
- sentence-transformers 5.2.0
- scikit-learn 1.8.0
- numpy 1.26.4

Foram realizadas 5 rodadas de testes, cada uma com um seed diferente, onde todos os classificadores eram testados. Em cada rodada e para cada classificador, foram utilizadas divisões de 80%/20% para treinamento e teste, respectivamente, realizadas de forma estratificada. Os embeddings das descrições dos produtos foram gerados uma única vez no início. Os classificadores mantiveram os parâmetros abaixo:

- KNN: `n_neighbors=[1, 2, 5, 8, 12]`
- Random Forest e Extra Trees: `n_estimators=300, max_depth=None` e `min_samples_split=2`
- SVM: `kernel=[linear, rbf]`, `C=1`, `probability=True` e `gamma=scale` para o kernel RBF
- Logistic Regression: `max_iter=2000, solver=lbfgs` e `C=1`
- MLP: `activation=relu`, `solver=adam`, `max_iter=2000` e `alpha=0.0001`
 - `hidden_layer_sizes=[128, 64]`
 - `hidden_layer_sizes=[256, 128, 64]`
 - `hidden_layer_sizes=[512, 256, 128]`
 - `hidden_layer_sizes=[1024, 512, 128]`

- VotingClassifier: sobre outros classificadores, com `voting=soft`
 - Extra Trees
 - SVM com `kernel=rbf`
 - MLPs com `hidden_layer_sizes=[512, 256, 128]` e `hidden_layer_sizes=[256, 128, 64]`
 - KNN com `n_neighbors=5`

4.3. Resultados

Em todos os testes, os modelos treinados com os embeddings formados pela concatenação da descrição original do produto mais a descrição sanitizada (somente com caracteres alfabéticos e palavras de até 2 caracteres removidas) superou os resultados obtidos com as descrições separadamente. Os resultados são analisados do ponto de vista da concatenação, apenas, sustentando um indicativo que uma descrição de produto pré processada com a técnica certa pode alcançar resultados ainda melhores.

Entre os classificadores avaliados, destacam-se o SVM com kernel RBF, os MLPs com arquiteturas mais profundas e o Voting Ensemble, que apresentaram desempenho superior e mais estável em todos os modelos de embeddings. Em particular, o Voting Ensemble obteve resultados próximos ou superiores aos melhores classificadores individuais, indicando que a combinação de modelos com diferentes vieses contribui para uma melhor generalização. Esse comportamento sugere que, em cenários reais de fiscalização, abordagens ensemble podem ser mais robustas frente à variabilidade e ambiguidade das descrições textuais.

Os resultados obtidos superam ou se equiparam aos apresentados em trabalhos correlatos, como é o caso de [Batista et al. 2018], que usou também os capítulos 22 e 90 do NCM, embora para um dataset diferente, mas com exatamente o mesmo objetivo. A principal diferença reside no fato de que o presente trabalho utiliza embeddings semânticos derivados de LLMs multilíngues, capazes de capturar relações linguísticas mais complexas, sem depender fortemente de engenharia manual de atributos. Isso evidencia um avanço metodológico relevante no contexto da classificação fiscal automatizada.

Corroborando com isso o experimento utilizando os capítulos 33, 61, 39, 87, usando apenas o modelo MiniLM, os embeddings foram gerados e classificados com os mesmos parâmetros, alcançou resultados de até 95% de acurácia (6).

Ao comparar os modelos de embeddings avaliados, observa-se uma superioridade consistente do modelo multilingual-e5-large em relação ao MiniLM e ao MPNet. Conforme apresentado na Tabela 4, o E5-LARGE alcançou as maiores acurácias para praticamente todos os classificadores testados, culminando em uma média geral próxima de 98,5%, conforme sintetizado em (5). Esse resultado pode ser atribuído ao processo de treinamento do modelo E5, que utiliza explicitamente marcadores de consulta (query) e resposta (passage), favorecendo tarefas de similaridade semântica e recuperação de informação, alinhadas ao problema abordado neste trabalho.

As matrizes de confusão (1b) e (1a) mostram que ambos os modelos têm desempenho elevado e equilibrado na separação das classes 22 e 90, com poucos erros e sem viés relevante. O SVM (RBF) apresenta 33 classificações incorretas, distribuídas de forma quase simétrica entre as classes, indicando uma fronteira de decisão estável. Já o

Tabela 1. Resultados dos classificadores quando usam embeddings gerados pelo modelo modelo MiniLM-L2-V2

Modelo	Classificador	Classe	Precisão	Reccal	F1-Score
MiniLM-L12-V2	KNN (k=1)	22	0.96	0.98	0.97
		90	0.98	0.96	0.97
	KNN (k=3)	22	0.95	0.98	0.97
		90	0.98	0.95	0.97
	KNN (k=5)	22	0.95	0.98	0.97
		90	0.98	0.95	0.97
	KNN (k=8)	22	0.94	0.99	0.96
		90	0.98	0.94	0.96
	KNN (k=12)	22	0.94	0.98	0.96
		90	0.98	0.93	0.96
	Random Forest	22	0.95	0.96	0.96
		90	0.96	0.95	0.96
	Extra Trees	22	0.95	0.96	0.96
		90	0.96	0.95	0.96
	SVM (Linear)	22	0.97	0.95	0.96
		90	0.95	0.97	0.96
	SVM (RBF)	22	0.98	0.97	0.98
		90	0.97	0.98	0.98
	L. Regression	22	0.96	0.95	0.96
		90	0.95	0.96	0.96
	MLP (hl: 128, 64)	22	0.97	0.97	0.97
		90	0.97	0.97	0.97
	MLP (hl: 256, 128, 64)	22	0.98	0.97	0.97
		90	0.97	0.98	0.98
	MLP (hl: 512, 256, 128)	22	0.98	0.97	0.98
		90	0.97	0.98	0.98
	MLP (hl: 1024, 512, 128)	22	0.98	0.98	0.98
		90	0.98	0.98	0.98
	Voting Ensemble	22	0.97	0.97	0.71
		90	0.97	0.97	0.98

Tabela 2. Resultados dos classificadores quando usam embeddings gerados pelo modelo modelo MPNET-Base-V2

Modelo	Classificador	Classe	Precisão	Reccal	F1-Score
MPNET-BaseV2	KNN (k=1)	22	0.96	0.98	0.97
		90	0.98	0.96	0.97
	KNN (k=3)	22	0.96	0.98	0.98
		90	0.98	0.96	0.97
	KNN (k=5)	22	0.96	0.99	0.97
		90	0.99	0.96	0.97
	KNN (k=8)	22	0.94	0.99	0.96
		90	0.99	0.94	0.96
	KNN (k=12)	22	0.95	0.99	0.97
		90	0.99	0.94	0.96
	Random Forest	22	0.96	0.96	0.96
		90	0.96	0.96	0.96
	Extra Trees	22	0.96	0.96	0.96
		90	0.96	0.96	0.96
	SVM (Linear)	22	0.98	0.97	0.98
		90	0.97	0.98	0.98
	SVM (RBF)	22	0.99	0.98	0.98
		90	0.98	0.99	0.98
	L. Regression	22	0.97	0.97	0.97
		90	0.97	0.97	0.97
	MLP (hl: 128, 64)	22	0.97	0.97	0.98
		90	0.98	0.97	0.97
	MLP (hl: 256, 128, 64)	22	0.97	0.98	0.98
		90	0.98	0.97	0.98
	MLP (hl: 512, 256, 128)	22	0.98	0.98	0.98
		90	0.98	0.98	0.98
	MLP (hl: 1024, 512, 128)	22	0.99	0.98	0.98
		90	0.98	0.99	0.98
	Voting Ensemble	22	0.98	0.98	0.98
		90	0.98	0.98	0.98

Tabela 3. Resultados dos classificadores quando usam embeddings gerados pelo modelo modelo E5-LARGE

Modelo	Classificador	Classe	Precisão	Reccal	F1-Score
E5-LARGE	KNN (k=1)	22	0.98	0.99	0.99
		90	0.99	0.98	0.99
	KNN (k=3)	22	0.98	0.99	0.98
		90	0.99	0.98	0.98
	KNN (k=5)	22	0.98	0.99	0.99
		90	0.99	0.98	0.99
	KNN (k=8)	22	0.98	0.99	0.98
		90	0.99	0.98	0.98
	KNN (k=12)	22	0.99	0.99	0.99
		90	0.99	0.99	0.99
	Random Forest	22	0.98	0.98	0.98
		90	0.98	0.98	0.98
	Extra Trees	22	0.99	0.98	0.98
		90	0.98	0.99	0.98
	SVM (Linear)	22	0.99	0.98	0.99
		90	0.98	0.99	0.99
	SVM (RBF)	22	1.00	0.98	0.99
		90	0.98	1.00	0.99
	L. Regression	22	0.99	0.98	0.99
		90	0.98	0.99	0.99
	MLP (hl: 128, 64)	22	0.99	0.97	0.98
		90	0.97	0.99	0.98
	MLP (hl: 256, 128, 64)	22	0.99	0.98	0.98
		90	0.98	0.99	0.98
	MLP (hl: 512, 256, 128)	22	0.99	0.98	0.98
		90	0.98	0.99	0.98
	MLP (hl: 1024, 512, 128)	22	0.99	0.98	0.98
		90	0.98	0.99	0.98
	Voting Ensemble	22	0.99	0.98	0.99
		90	0.98	0.99	0.99

Tabela 4. Acurácia dos classificadores para os embeddings gerados por cada modelo de LLM

Classificador	Modelo		
	MiniLM	MPNET	E5-LARGE
KNN (k=1)	96.93%	96.93%	98.57%
KNN (k=3)	96.71%	97.21%	98.36%
KNN (k=5)	96.57%	97.07%	98.57%
KNN (k=8)	96.07%	96.36%	98.43%
KNN (k=12)	95.79%	96.50%	98.57%
Random Forest	95.57%	96.00%	98.00%
Extra Trees	95.71%	95.93%	98.21%
SVM (Linear)	96.14%	97.64%	98.57%
SVM (RBF)	97.71%	98.14%	98.64%
L. Regression	95.64%	97.14%	98.64%
MLP (hl: 128, 64)	96.93%	97.43%	98.14%
MLP (hl: 256, 128, 64)	97.50%	97.79%	98.29%
MLP (hl: 512, 256, 128)	97.71%	97.86%	98.29%
MLP (hl: 1024, 512, 128)	97.64%	98.07%	98.36%
Voting Ensemble	97.71%	98.14%	98.79%

Tabela 5. Média da acurácia dos classificadores por modelo de LLM




Tabela 6. Acurácia dos classificados para os capítulos 33, 61, 39, 87

Classificador	Modelo MiniLM Capítulos 33, 61, 39, 87
	Acurária
KNN (k=1)	94.29%
MLP (hl: 1024, 512, 128)	94.29%
Voting Ensemble	95.08%

KNN ($k=5$) reduz esse número para 20 erros, sugerindo melhor captura da estrutura local dos dados. Em ambos os casos, as diferenças são pequenas e devem ser interpretadas considerando a variabilidade entre diferentes divisões dos dados.




Figura 1. Comparação das matrizes de confusão para diferentes modelos

5. Conclusões

Do ponto de vista prático, os resultados indicam que a abordagem proposta é uma alternativa viável no apoio à fiscalização tributária.

O campo da fiscalização tributária é vasto, o que permite a progressão deste experimento em muitos outros trabalhos. Por exemplo, a inclusão de outros capítulos de NCM e testes com códigos mais granulares, incluindo posições, itens e subitens. Também é possível conduzir trabalhos com outras informações fiscais, como o Código Fiscal de Operações e Prestações (CFOP). Além disso tudo, a implantação das técnicas testadas em ambientes produtivos reais surge como uma sequência natural, visando o pleno uso da tecnologia respaldada em pesquisa acadêmica.

O treinamento de um LLM especializado no domínio fiscal e tributário é uma alternativa prática para alcançar ainda mais precisão e performance computacional. Os experimentos demonstraram, inclusive, que um LLM mais robusto, como o E5-LARGE, ainda que generalista em sua proposta, propiciou melhores resultados (5) que os modelos mais simples de linguagem (MiniLM e MPNET). Um exemplo clássico nesse contexto é o BioBERT, que foi treinado com grandes volumes de artigos do domínio da saúde. Essa especialização permitiu ganhos substanciais em tarefas como reconhecimento de entidades biomédicas, extração de relações e classificação de textos clínicos, evidenciando que o conhecimento contextual adquirido durante o pré-treinamento é crucial para o desempenho em domínios altamente técnicos [Lee et al. 2019]. A produção de um LLM treinado especificamente para o contexto fiscal tributário vai propiciar maior precisão nas análises e performance em velocidade e recursos computacionais.

Referências

Batista, R. d. A., Bagatini, D. D. S., and Frozza, R. (2018). Classificação automática de códigos ncm utilizando o algoritmo naïve bayes. In *Revista Brasileira de Sistemas de Informação*, 11(2), 4-29, Brasil.

- Brasil (1988). Constituição da república federativa do brasil de 1988. Disponível em: https://www.planalto.gov.br/ccivil_03/constituicao/constituicao.htm. Acesso em: 4 jan. 2026.
- Brasil (1996). Lei complementar nº 87, de 13 de setembro de 1996 (lei Kandir). Dispõe sobre o ICMS. Disponível em: http://www.planalto.gov.br/ccivil_03/leis/lcp/lcp87.htm. Acesso em: 4 jan. 2026.
- Brasil (2023). Emenda constitucional nº 132, de 20 de dezembro de 2023. Altera o Sistema Tributário Nacional. Disponível em: http://www.planalto.gov.br/ccivil_03/Constituicao/ConstituicaoCompilado.htm. Acesso em: 4 jan. 2026.
- Cer, D. et al. (2018). Universal sentence encoder. In *Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing: System Demonstrations*.
- ENCAT (2020a). Manual de orientação ao contribuinte da nota fiscal eletrônica (nf-e). Disponível em: <https://www.nfe.fazenda.gov.br/portal/exibirArquivo.aspx?conteudo=QxZt3jQ5w1M=>. Acesso em: 4 jan. 2026.
- ENCAT (2020b). Manual de orientação ao contribuinte da nota fiscal eletrônica (nf-e): Anexo i – Leiaute da nf-e. Disponível em: <https://www.nfe.fazenda.gov.br/portal/exibirArquivo.aspx?conteudo=QxZt3jQ5w1M=>. Acesso em: 4 jan. 2026.
- Jatobá, A. E. A., Moura, D. L. L., Martins, I. C., Ramos, H. S., and Aquino, A. L. L. (2021). Calt: Uma ferramenta automática para cobrança do ICMS em operações interestaduais. In *Anais do Workshop de Computação Aplicada em Governo Eletrônico (WCGE)*, Porto Alegre, RS, Brasil. Sociedade Brasileira de Computação (SBC).
- Lee, J., Yoon, W., Kim, Sungdong, Kim, D., Kim, S., So, C., and Kang, J. (2019). BioBERT: a pre-trained biomedical language representation model for biomedical text mining. *Bioinformatics (Oxford, England)*, 36.
- Madeira, R. d. O. C. (2015). Aplicação de técnicas de mineração de texto na detecção de discrepâncias em documentos fiscais. Master's thesis, Fundação Getúlio Vargas. Escola de Matemática Aplicada.
- Mendonça, A. E. G. d., Coutinho, L. R., and Mariano, R. G. (2022). Modelos de aprendizagem de máquina para identificação de mercadorias a partir da descrição do item na nota fiscal eletrônica. In *Anais do Latin American Symposium on Digital Government (LASDiGov)*, São Luís, MA, Brasil. Sociedade Brasileira de Computação.
- Paula Junior, G. G. d., Silveira, Raul Neto, M. R. M., and Fonseca (2004). Uma rede neural artificial de múltiplas camadas aplicada ao combate à sonegação fiscal de ICMS. In *Anais do XXXVI Simpósio Brasileiro de Pesquisa Operacional (SBPO)*, pages 2031–2041, Brasil.
- Reimers, N. and Gurevych, I. (2019). Sentence-BERT: Sentence embeddings using Siamese BERT-networks. In *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics.

SEFAZ-MA (2025). Portal Único do siscomex. Disponível em: <https://sistemas1.sefaz.ma.gov.br/arrecadacaoonline/arrecadacaoperiodo.html>. Acesso em: 01 jan. 2025.

SISCOMEX (2025). Portal Único do siscomex. Disponível em: <https://portalunico.siscomex.gov.br/classif/#/sumario?perfil=publico>. Acesso em: 4 jan. 2026.

Wang, L., Yang, N., Huang, X., Yang, L., Majumder, R., and Wei, F. (2024). Multilingual e5 text embeddings: A technical report.

WCO (2026). World customs organization organisation mondiale des douanes. Disponível em: <https://www.wcoomd.org/en/topics/nomenclature/overview.aspx>. Acesso em: 4 jan. 2026.